

1.产生的背景

- 从1970年开始，大多数的公司数据存储和维护使用的是关系型数据库
- 大数据技术出现后，很多拥有海量数据的公司开始选择像Hadoop的方式来存储海量数据
- Hadoop使用分布式文件系统HDFS来存储海量数据，并使用MapReduce来处理。Hadoop擅长于存储各种格式的庞大的数据，任意的格式甚至非结构化的处理
- 但是Hadoop存在局限性
 - hdfs不支持随机读写，仅支持顺序读写，hdfs适合批量数据操作，实际需要有随机读写的工具
- HBase采用java于开发，基于HDFS，是一个支持高效随机读写的NoSQL数据库

2.HBase的基本介绍

- NoSQL是一个通用术语，泛指一个数据库并不是使用SQL作为主要语言的非关系型数据库
- HBase是BigTable的开源java版本，是建立在HDFS之上，提供高可靠性、高性能、列存储、实时读写NoSQL的数据库系统
- HBase仅能通过主键（row key）和主键的range来检索数据，本质是一个存储容器。仅支持单行事务，不支持多行事务，不支持SQL
 - 1.主键查询rowkey
 - 2.主键范围查询rowkey
 - 3.全表查询
- 主要用来存储结构化和半结构化的松散数据
- HBase查询数据功能很简单，不支持join等复杂操作，不支持复杂的事务（行级的事务），从技术上来说，HBase更像是一个【数据存储】而不是【数据库】，因为HBase缺少RDBMS中的许多特性，例如带类型的列、二级索引以及高级查询语言等
- HBase中支持的数据类型：byte[] --所有数据都是字节
- 与Hadoop一样，HBase目标主要依靠横向扩展，通过不断增加廉价的商用服务器，来增加存储和处理能力，例如，把集群中从10个节点扩展到20个节点，存储能力和处理能力都会加倍
- HBase中的表特点
 - 大：一个表可以有上十亿行，上百万列
 - 面向列：面向列（族）的存储和权限控制，列（族）独立检索
 - 稀疏：对于空（null）的列，并不占用存储空间，因此，表可以设计的非常稀疏

3.HBase的特点

- **强一致性读/写**：HBase 不是“最终一致的”数据存储，它非常适合于诸如高速计数器聚合等任务
- **自动分块**：HBase表通过**Region**分布在集群上，随着数据的增长，区域被自动拆分成和重新分布
- **自动RegionServer故障转移**
- Hadoop/HDFS集成：HBase支持HDFS开箱即用作为其分布式文件系统

- MapReduce：HBase通过MapReduce支持大规模并行处理，将HBase用作源和接收器
- **Java Client API**：HBase支持易于使用的Java API进行编程访问
- Thrift/REST API
-
- 块缓存换布隆过滤器：HBase支持块Cache和Bloom过滤器进行大容量查询优化
- 运行管理：HBase为业务洞察和JMX度量提供内置网页

4.HBase与RDBMS、HDFS、Hive的区别

	HBase	RDBMS
结构	<div>1. 以表形式存在</div> <div>2. 支持HDFS文件系统</div> <div>3. 使用行键（row key）</div> <div>4. 原生支持分布式存储、计算引擎</div> <div>5. 使用行、列、列族和单元格</div>	<div>1. 数据库以表的形式存在</div> <div>2. 支持FAT、NTFS、EXT、文件系统</div> <div>3. 使用主键（PK）</div> <div>4. 通过外部中间件可以支持分库分表，但底层还是单机引擎</div> <div>5. 使用行、列、单元格</div>
功能	<div>1. 支持向外扩展</div> <div>2. 使用API和MapReduce、Spark、Flink来访问HBase表数据</div> <div>3. 面向列簇，即每一个列簇都是一个连续的单元</div> <div>4. 数据总量不依赖具体某台机器，而取决于机器数量</div> <div>HBase不支持ACID（Atomicity、Consistency、Isolation、Durability）</div> <div>5. 适合结构化数据和非结构化数据</div> <div>6. 一般都是分布式的</div> <div>7. HBase不支持事务，支持的是单行数据的事务操作</div> <div>不支持Join</div>	<div>1. 支持向上扩展（买更好的服务器）</div> <div>2. 使用SQL查询</div> <div>3. 面向行，即每一行都是一个连续单元</div> <div>4. 数据总量依赖于服务器配置</div> <div>5. 具有ACID支持</div> <div>6. 适合结构化数据</div> <div>7. 传统关系型数据库一般都是中心化的</div> <div>8. 支持事务</div> <div>9. 支持Join</div>

- hbase：以表的形式存储数据，不支持sql，不支持复杂事务，仅支持单行事务，数据分布式存储，结构化数据和半结构化数据，不支持join操作
- rdbms：以表的形式存储数据，支持sql，支持复杂事务，中心化存储，支持join操作

HBase	HDFS
<ol style="list-style-type: none"> 1. HBase构建在HDFS之上，并为大型表提供快速记录查找(和更新) 2. HBase内部将大量数据放在HDFS中名为「StoreFiles」的索引中，以便进行高速查找 3. Hbase比较适合做快速查询等需求，而不适合做大规模的OLAP应用 	<ol style="list-style-type: none"> 1. HDFS是一个非常适合存储大型文件的分布式文件系统 2. HDFS它不是一个通用的文件系统，也无法在文件中快速查询某个数据

- Hbase 依赖于hdfs，数据存在hdfs上，支持高效的随机读写
- hdfs 分布式文件系统，适合批量存储，不支持随机读写

HBase	Hive
<ol style="list-style-type: none"> 1. NoSQL数据库 2. 是一种面向列存储的非关系型数据库。 3. 用于存储结构化和非结构化的数据 4. 适用于单表非关系型数据的存储，不适合做关联查询，类似JOIN等操作。 5. 基于HDFS 6. 数据持久化存储的体现形式是Hfile，存放于DataNode中，被ResionServer以region的形式进行管理 6. 延迟较低，接入在线业务使用 8. 面对大量的企业数据，HBase可以直线单表大量数据的存储，同时提供了高效的数据访问速度 	<ol style="list-style-type: none"> 1. 数据仓库工具 2. Hive的本质其实就相当于将HDFS中已经存储的文件在Mysql中做了一个双射关系，以方便使用HQL去管理查询 3. 用于数据分析、清洗 4. Hive适用于离线的数据分析和清洗，延迟较高 5. 基于HDFS、MapReduce 6. Hive存储的数据依旧在DataNode上，编写的HQL语句终将是转换为MapReduce代码执行

总结: hbase与hive

Hive和Hbase是两种基于Hadoop的不同技术

Hive是一种类SQL的引擎，并且运行MapReduce任务

Hbase是一种在Hadoop之上的NoSQL 的Key/value数据库

这两种工具是可以同时使用的。就像用Google来搜索，用FaceBook进行社交一样，Hive可以用来进行统计查询，HBase可以用来进行实时查询，数据也可以从Hive写到HBase，或者从HBase写回Hive

- hbase：依赖于hdfs，数据存在hdfs上，nosql存储容器，延迟较低，可以接入在线业务
- hive：依赖于hdfs，mapreduce任务，数仓分析工具，延迟较高，一般用作离线业务分析中

5.HBase的表模型

- 在HBase中，数据存储在有行和列的表中。这是看起来关系数据库（RDBMS）一样，但将HBASE表看成是多

rowKey	Column Family1 userInfo store1 store2				Column Family2 addressInfo store3						Column FamilyN...				timeStamp	versionNum 版本号
	name	age	sex	password	address	from	phone	email	salary	regtime		
1	zhangsan	18	1	123456	地球村	火星	13612345678	666@163.com	500	2018/12/20 12:23					1545307281	1
2	李四	28	1	123456	地球村	月球	13612345678	667@163.com	600	2018/12/21 12:23					1545393681	2
3	黄晓明	58	1	123456	地球村	土星	13612345678	668@163.com	800	2018/12/21 12:23					1545480081	3
4	按住啾baby	25	0	123456	地球村	韩国整容	13612345678	669@163.com	15000	2018/12/22 12:23					1545566481	1

- 表 (Table) : HBase中数据都是以表形式来组织的, HBase中的表由多个行组成
- 行键 (row key) : 类似于数据库中的主键, 只能通过rowkey进行查找, rowkey不能重复, rowkey是以字典序进行排序
 - HBase中的行有一个rowkey (行键) 和一个或者多个列组成, 列的值与rowkey、列相关联
 - 行在存储是按行键的字典序排序
 - 行键的设计非常重要, 尽量让相关的行存储在一起
- 列 (Column) : HBase中的列有列族 (column family) + 列限定符 (列名) (column Qualifier) 组成
 - 表示如下: 列族名: 列限定符 例如: C1:USER_ID C1:SEX
- 列族 (Column Family) :
 - 出于性能原因, 列族将一组列及其值组织在一起
 - 每个列族都有一个存储属性: 例如 是否应该换成在内存中, 数据如何被压缩等
 - 表中的每一行都有相同的列族, 但在列族中不存储任何内容
 - 所有的列族的数据全部都存储在一块 (文件系统HDFS)
 - HBase官方建议所有的列族保持一样的列, 并且将同一类的列放在一个列族中
- 列限定符 (Column Qualifier) : 一个列限定符必然属于某个列族, 创建表时可以先不指定限定符, 添加数据时再动态指定
 - 列族中包含一个个的列限定符, 这样可以为存储的数据提供索引
 - 列族在创建表的时候是固定的, 但列限定符是不做限制的
 - 不同的列可能会存在不同的列标识符
- 单元格 (Cell) : 单元格是行、列族和列限定符的组合, 包含一个值和一个时间戳, 数据以二进制存储
 - rowkey+ (列族+列限定符) 列名, 每个cell都有时间戳和版本号
- 版本号 (version num) : 每条数据逗号有版本号的概念
 - 每条数据都可以有多个版本号, 默认值为系统时间戳, 类型为Long
- 时间戳 (timeStamp) : 每个数据都会有时间戳的概念
 - 在向HBase插入更新数据时, HBase默认会将当前操作的时间记录下来, 当然也可以人为指定时间
 - 不同版本的数据按照时间倒序排序, 即最新的数据排在最前面

6.HBase命令

• 进入HBase客户端

```
1 hbase shell
```

• 查看帮助命令

```
1 help
```

• 查看当前数据库中有哪些表

```
1 list
```

• 创建一张表

```
1 创建user表，包含info、data两个列族
2 create "表名", "列族名1"[, "列族名2", ...] # 方括号表示内容时可选的，单引号双引号都可以
3 create 'user', 'info', 'data'
4 或者，NAME是列族名，VERSIONS是版本号
5 create 'user', {NAME => 'info', VERSIONS => '3'}, {NAME => 'data'}
```

• 添加数据操作

```
1 格式
2 put "表名", "rowkey", "列族:列限定符", "值"
3
4 put "day01", "rk001", "f1:name", "张三"
5 rowkey是自己设定的
6 列族是创建表时必须指定一个
7 列限定符时插入数据时指定
8
9 day01
10
11          f1
12 name      age birthday
13 rk001 zhangsan 18 2000-3-7
14 rk002 lisi     20 2002-3-7
15
16 向user表中插入信息，row key为rk0001，列族info中添加name列标示符，值为zhangsan
17 格式: put 表名 , rowkey , 列族: 列名, 值
18 hbase(main):011:0> put 'user', 'rk0001', 'info:name', 'zhangsan'
19
20 向user表中插入信息，row key为rk0001，列族info中添加gender列标示符，值为female
21 格式: put 表名, rowkey, 列族: 列名 , 值
```

```

21 hbase(main):012:0> put 'user', 'rk0001', 'info:gender', 'female'
22
23 向user表中插入信息，row key为rk0001，列族info中添加age列标示符，值为20
24 put 表名， rowkey， 列族：列名， 值
25
26 hbase(main):013:0> put 'user', 'rk0001', 'info:age', 20
27
28 向user表中插入信息，row key为rk0001，列族data中添加pic列标示符，值为picture
29 put 表名， rowkey， 列族：列名， 值
30
31 hbase(main):014:0> put 'user', 'rk0001', 'data:pic', 'picture'

```

● 查询数据操作

```

1 格式
2 get "表名", "rowkey" [, "列族1", "列族2"] [, "列族:列限定符"] [, "列族1", "列族2:列限定符"]
3
4 1.1通过rowkey进行查询
   获取user表中row key为rk0001的所有信息
5 格式： get 表名,rowkey
6
7 hbase(main):015:0> get 'user', 'rk0001'
8
9 1.2、查看rowkey下面的某个列族的信息
   获取user表中row key为rk0001，info列族的所有信息
10 格式： get 表名,rowkey,列族
11
12 hbase(main):016:0> get 'user', 'rk0001', 'info'
13
14 1.3、查看rowkey指定列族指定字段的值
   获取user表中row key为rk0001，info列族的名字、age列标示符的信息
15 格式： get 表名,rowkey,列族：列名,列族：列名
16
17 hbase(main):017:0> get 'user', 'rk0001', 'info:name', 'info:age'
18
19 1.4、查看rowkey指定多个列族的信息
   获取user表中row key为rk0001，info、data列族的信息
20 格式： get 表名,rowkey,列族1，列族2...
21
22 hbase(main):018:0> get 'user', 'rk0001', 'info', 'data'
23
24 或者你也可以这样写

```

```

20 hbase(main):019:0> get 'user', 'rk0001', {COLUMN => ['info', 'data']}
    或者你也可以这样写，也行
21 hbase(main):020:0> get 'user', 'rk0001', {COLUMN => ['info:name', 'data:pic']}
22
23 1.5、指定rowkey与列值查询
    获取user表中row key为rk0001，cell的值为zhangsan的信息
24 格式：get 表名,rowkey,{FILTER=>"VlaueFilter(=,'binary:值')"}
25 hbase(main):030:0> get 'user', 'rk0001', {FILTER => "ValueFilter(=, 'binary:zhangsan')"}
26

```

● scan命令查询

```

27 格式
28 1 scan 进行全表扫描
29 scan "表名" # 全表扫描，会把整张表的数据都拿到客户端，一般不会直接进行scan操作
30
31 scan "表名" [, {COLUMNS=>["列族1","列族2"...], VERSIONS=>N, LIMIT=>N,
    FORMATTER=>'toString' }]
32
33 LIMIT=>N 表示显示前N条数据
34 VERSIONS=>N 表示显示n个版本
35 FORMATTER=>'toString' 表示显示字符串，如果是中文 就显示汉字
36
37
38 1.6、查询所有数据 ： 查询user表中的所有信息
39 scan 'user'
40 //显示中文
41 scan 'user' , {FORMATTER => 'toString'}
42 //显示前3个，并显示中文
43 scan 'user' , {LIMIT => 3,FORMATTER => 'toString'}
44
45 1.7、列族查询： 查询user表中列族为info的信息
46 scan 'user', {COLUMNS => 'info'}
47
48 scan 'user', {COLUMNS => 'info', RAW => true, VERSIONS => 5}
49
50 scan 'user', {COLUMNS => 'info', RAW => true, VERSIONS => 3}
51
52 1.8、多列族查询： 查询user表中列族为info和data的信息
53 scan 'user', {COLUMNS => ['info', 'data']}
54
55 scan 'user', {COLUMNS => ['info:name', 'data:pic']}
56

```


53

54 **1.9**、指定列族与某个列名查询

55 查询user表中列族为info、列标示符为name的信息

56 `scan 'user', {COLUMNS => 'info:name'}`

57

58 **1.10**、指定列族与列名以及限定版本查询

59 查询user表中列族为info、列标示符为name的信息,并且版本最新的5个

60 `scan 'user', {COLUMNS => 'info:name', VERSIONS => 5}`

61

62 **1.12**、指定多个列族与按照数据值模糊查询

63 查询user表中列族为info和data且列标示符中含有a字符的信息

64 `scan 'user', {COLUMNS => ['info', 'data'], FILTER => "(QualifierFilter(=,'substring:a'))"}`

65

66 进行范围查询

67 格式

68 `scan "表名", {STARTROW=>'rowkey1', ENDROW=>'rowkey2'}`

69 # 范围是左闭右开, 包含左边, 不包含右边

70 **1.13**、rowkey的范围值查询

71 查询user表中列族为info, rk范围是[rk0001, rk0003)的数据

72 `scan 'user', {COLUMNS => 'info', STARTROW => 'rk0001', ENDROW => 'rk0003'}`

73

74 **1.14**、指定rowkey模糊查询

75 查询user表中row key以rk字符开头的

76 `scan 'user', {FILTER=>"PrefixFilter('rk')"}`

77

78 **1.15**、指定数据范围值查询

79 查询user表中指定范围的数据

80 `scan 'user', {TIMERANGE => [1392368783980, 1392380169184]}`

81

● 过滤器的查询地址

- <http://hbase.apache.org/2.2/devapidocs/index.html>

● 更新数据操作


```
1 1、更新数据值
2 更新操作同插入操作一模一样，只不过有数据就更新，没数据就添加
3 2、更新版本号
4 将user表的f1列族版本号改为5
5 hbase(main):050:0> alter 'user', NAME => 'info', VERSIONS => 5
```

● 删除操作

```
1 格式
2 delete "表名", "rowkey", "列族:列限定符"
3 delete 删除的是指定列的最新值，剩下的是倒数第二新的值
4
5 格式
6 deleteall "表名", "rowkey", "列族:列限定符"
7 deleteall把整个列删除
8
9 deleteall "day01", "rk001", "f1:name"
10
11 deleteall "表名", "rowkey"
12 把指定的rowkey这一行删掉
13
14 1、指定rowkey以及列名进行删除
15 删除user表row key为rk0001，列标示符为info:name的数据
16 hbase(main):045:0> delete 'user', 'rk0001', 'info:name'
17 2、指定rowkey，删除一整行数据
18 hbase(main):045:0> deleteall 'user', 'rk0001'
19 注意：
20 1. deleteall 是在 hbase 2.0版本后出现的，在2.0版本之前，只需要使用delete这个命令即可完成所有的删除数据工作，
21 2. delete删除数据时候，只会删除最新版本的数据，而deleteall 直接将对应数据的所有的历史版本全部删除
22 3、删除一个列族：
23 alter 'user', NAME => 'info', METHOD => 'delete' 或 alter 'user', 'delete' => 'info'
24
25 格式
26 truncate "表名"
27 4、清空表数据
28 hbase(main):017:0> truncate 'user'
29
30 1 先把表禁掉
```

```
31 disable "表名"
32 2 删除表
33 drop "表名"
34
35 5、删除表
36 首先需要先让该表为disable状态，使用命令： hbase(main):049:0> disable 'user'
37 然后才能drop这个表，使用命令： hbase(main):050:0> drop 'user'
38 (注意：如果直接drop表，会报错： Drop the named table. Table must first be disabled)
```

• 统计一张表有多少行数据

```
1 hbase(main):053:0> count 'user'
```

• 高级命令

• 过滤器查询操作

```
1 格式
2
3 scan "表名", {FILTER=>"过滤器名称(比较器运算符, 比较器表达式)"}
4
5
6 常见的过滤器
7 1 rowkey过滤器
8     RowFilter: 实现行键的比较和过滤
9     PrefixFilter: rowkey前缀过滤器
10
11 2 列族过滤器
12     FamilyFilter: 过滤列族
13
14 3 列名过滤器
15     QualifierFilter: 只显示对应的列名
16
17 4 列值过滤器
18     valueFilter: 找到符合条件的键值对
19     SingleColumnValueFilter 指定的列族中进行比较 把满足条件的留下
20     SingleColumnExcludeFilter 把不满足条件的留下
21 5 其他过滤器
22     PageFilter: 分页查询
23
24
```

```
25 比较运算符
26 > < >= <= != =
27
28
29 比较器
30 BinaryComparator 匹配完整字节
31 BinaryPrefixComparator 匹配字节前缀
32 NullComparator 匹配空值
33 SubstringComparator 模糊匹配
34
35 比较器表达式
36 binary:值
37 'binary:zhangsan'
38
39 binaryprefix:值
40 'binaryprefix:zhang'
41 null
42
43 substring:值
44 'substring:abc'
45
```

• 其他高级

```
1 status 显示服务器状态 “例如: hbase(main):058:0> status 'node01'
2 whoami : 显示HBase当前用户, 例如: hbase> whoami
3 list : 显示当前所有的表
4 count: 统计指定表的记录数, 例如: hbase> count 'user'
5 describe : 展示表结构信息
6 exists: 检查表是否存在, 适用于表量特别多的情况
7 is_enabled、is_disabled: 检查表是否启用或禁用
8 alter : 该命令可以改变表和列族的模式,
  例如: 为当前表增加列族: hbase> alter 'user', NAME => 'CF2', VERSIONS => 2
  为当前表删除列族: hbase(main):002:0> alter 'user', 'delete' => 'CF2'
9 disable/enable : 禁用一张表/启用一张表
10 drop : 删除一张表, 记得在删除表之前必须先禁用
11 truncate : 禁用表-删除表-创建表
```

7.HBase的javaAPI操作

准备工作

- 创建maven项目
 - 1 构建父工程, pydata28sz
 - 2 删除src目录
 - 3 创建子工程 day01_hbase
- 导入相关依赖

```
1  <?xml version="1.0" encoding="UTF-8"?>
2  <project xmlns="http://maven.apache.org/POM/4.0.0"
3      xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
4      xsi:schemaLocation="http://maven.apache.org/POM/4.0.0
5      http://maven.apache.org/xsd/maven-4.0.0.xsd">
6      <parent>
7          <artifactId>pydata28sz</artifactId>
8          <groupId>cn.itcast</groupId>
9          <version>1.0-SNAPSHOT</version>
10     </parent>
11     <modelVersion>4.0.0</modelVersion>
12     <artifactId>day01_hbase</artifactId>
13
14     <properties>
15         <maven.compiler.source>8</maven.compiler.source>
16         <maven.compiler.target>8</maven.compiler.target>
17     </properties>
18
19     <repositories>
20         <repository>
21             <id>aliyun</id>
22             <url>http://maven.aliyun.com/nexus/content/groups/public/</url>
23             <releases><enabled>true</enabled></releases>
24             <snapshots><enabled>false</enabled></snapshots>
25         </repository>
26     </repositories>
27
28     <dependencies>
29         <dependency>
30             <groupId>org.apache.hbase</groupId>
31             <artifactId>hbase-client</artifactId>
```

```

32         <version>2.1.0</version>
33     </dependency>
34     <dependency>
35         <groupId>commons-io</groupId>
36         <artifactId>commons-io</artifactId>
37         <version>2.6</version>
38     </dependency>
39     <dependency>
40         <groupId>junit</groupId>
41         <artifactId>junit</artifactId>
42         <version>4.12</version>
43         <scope>test</scope>
44     </dependency>
45     <dependency>
46         <groupId>org.testng</groupId>
47         <artifactId>testng</artifactId>
48         <version>6.14.3</version>
49     </dependency>
50 </dependencies>
51
52 <build>
53     <plugins>
54         <plugin>
55             <groupId>org.apache.maven.plugins</groupId>
56             <artifactId>maven-compiler-plugin</artifactId>
57             <version>3.1</version>
58             <configuration>
59                 <target>1.8</target>
60                 <source>1.8</source>
61             </configuration>
62         </plugin>
63     </plugins>
64 </build>
65
66 </project>

```

• 创建表

- 1 步骤
- 2 **1** 建立链接，链接到hbase

```
3 2 从链接对象中获取管理对象，
4     Admin对象，对表的管理
5     Table 对表的数据进行管理
6 3 执行相关操作：创建表 增加数据 删除
7 4 处理结果-- 有可能不需要的
8 5 释放资源
```

```
1 import org.apache.hadoop.conf.Configuration;
2 import org.apache.hadoop.hbase.HBaseConfiguration;
3 import org.apache.hadoop.hbase.TableName;
4 import org.apache.hadoop.hbase.client.*;
5 import org.testng.annotations.Test;
6
7 import java.io.IOException;
8
9 public class TableAdminTest {
10     @Test
11     // 创建表
12     public void test01() throws IOException {
13         //1 建立链接，链接到hbase
14         Configuration conf = HBaseConfiguration.create();
15         conf.set("hbase.zookeeper.quorum",
16 "node1.itcast.cn,node2.itcast.cn,node3.itcast.cn");
17
18         Connection hbConn = ConnectionFactory.createConnection(conf);
19         //2 从链接对象中获取管理对象，
20         //Admin对象，对表的管理
21         //Table 对表的数据进行管理
22         Admin admin = hbConn.getAdmin();
23
24         //3 执行相关操作：创建表 增加数据 删除
25         // 命令行创建表
26         // create "表名", "列族名"
27         boolean flag = admin.tableExists(TableName.valueOf("WATER_BILL"));
28         if (!flag) {
29             // 如果代码执行到这里，表示表不存在
30             // 3.1 创建列族相关的构造器，设置列族名
31             ColumnFamilyDescriptorBuilder columnFamilyDescriptorBuilder =
32 ColumnFamilyDescriptorBuilder.newBuilder("C1".getBytes());
```

```

31         ColumnFamilyDescriptor columnFamilyDescriptor =
columnFamilyDescriptorBuilder.build();
32         // 3.2 创建表相关的构造器，设置表名
33         TableDescriptorBuilder tableDescriptorBuilder =
TableDescriptorBuilder.newBuilder(TableName.valueOf("WATER_BILL"));
34         // 3.3 别螺祖构造器和表构造器关联，确定列族和表名
35         tableDescriptorBuilder.setColumnFamily(columnFamilyDescriptor);
36         TableDescriptor desc = tableDescriptorBuilder.build();
37
38         // 3.4 创建表
39         admin.createTable(desc);
40     }
41     //4 处理结果-- 有可能不需要的
42     //5 释放资源 下面没有顺序要求
43     hbConn.close();
44     admin.close();
45 }
46 }
47

```

● 添加数据

- 1 创建Hbase链接对象
- 2 获取table对象，对表进行管理
- 3 执行操作：添加数据
- 4 处理结果
- 5 释放资源

```

1     /**
2     * 1 创建Hbase链接对象
3     *
4     * 2 获取table对象，对表进行管理
5     *
6     * 3 执行操作：添加数据
7     *
8     * 4 处理结果
9     *
10    * 5 释放资源
11    */
12    // 插入数据
13    @Test

```



```

14     public void test02() throws IOException {
15         // 1 创建Hbase链接对象
16         Configuration conf = HBaseConfiguration.create();
17         conf.set("hbase.zookeeper.quorum",
18             "node1.itcast.cn,node2.itcast.cn,node3.itcast.cn");
19
20         Connection hbConn = ConnectionFactory.createConnection(conf);
21
22         // 2 获取table对象，对表进行管理
23         Table table = hbConn.getTable(TableName.valueOf("WATER_BILL"));
24
25         // 3 执行操作：添加数据
26         // 命令行 put "表名", "rowkey", "列族:列限定符", "值"
27         Put put = new Put(Bytes.toBytes("4944191"));
28         put.addColumn("C1".getBytes(), "NAME".getBytes(), "登卫红".getBytes());
29         put.addColumn("C1".getBytes(), "ADDR".getBytes(), "贵州省铜仁市德江县7单元267
30             室".getBytes());
31         put.addColumn("C1".getBytes(), "SEX".getBytes(), "男".getBytes());
32         put.addColumn("C1".getBytes(), "PAY_TIME".getBytes(), "2020-05-10".getBytes());
33
34         // 执行put操作
35         table.put(put);
36
37         // 4. 处理结果
38         // 5. 释放资源
39         table.close();
40         hbConn.close();
41     }

```

● 抽取公共方法

```

1     private String tableName = "WATER_BILL";
2     private Connection hbConn ;
3     private Table table;
4     private Admin admin;
5
6
7     @Before
8     public void before() throws IOException {
9         // 1 创建Hbase链接对象

```

```

10     Configuration conf = HBaseConfiguration.create();
11     conf.set("hbase.zookeeper.quorum",
12         "node1.itcast.cn,node2.itcast.cn,node3.itcast.cn");
13
14     hbConn = ConnectionFactory.createConnection(conf);
15
16     // 2 获取admin table对象, 对表进行管理
17     table = hbConn.getTable(TableName.valueOf(tableName));
18     admin = hbConn.getAdmin();
19 }
20
21 @Test
22 public void test03() {
23     //
24 }
25
26 @After
27 public void after() throws IOException {
28     // 释放资源
29     admin.close();
30     table.close();
31     hbConn.close();
32 }

```

● 查询某一条数据

```

1  @Test
2  public void test03() throws IOException {
3      //查询数据
4      //3.执行操作
5      //get "表名","rowkey","列族: 列限定符"
6      Get get = new Get(Bytes.toBytes("4944191"));
7      //一行数据
8      Result result = table.get(get);
9      //4.处理结果,把result单元格转成一个列表
10     List<Cell> listCells = result.listCells();
11     //遍历list,cellUtil工具类
12     for (Cell cell : listCells) {
13         //4.1获取rowkey
14         byte[] bytes = CellUtil.cloneRow(cell);
15         //转成一个String

```

```

16      String rowkey = Bytes.toString(bytes);
17      //4.2获取列族
18      byte[] bytes1 = CellUtil.cloneFamily(cell);
19      String s = Bytes.toString(bytes1);
20      //4.3列限定符
21      byte[] bytes2 = CellUtil.cloneQualifier(cell);
22      String s1 = Bytes.toString(bytes2);
23      //4.4获取值
24      byte[] bytes3 = CellUtil.cloneValue(cell);
25      String s2 = Bytes.toString(bytes3);
26      System.out.println("rowkey:" + rowkey + " ,列族: " + s + " ,列限定符: " + s1 +
    " ,值: " + s2);
27  }
28 }

```

● 删除数据

```

1  @Test
2  public void test04() throws IOException {
3      //删除数据
4      // delete "表名","rowkey","列族: 列限定符"
5      Delete delete = new Delete(Bytes.toBytes("4944191"));
6      //删除列限定符
7      //      delete.addColumn("C1".getBytes(), "NAME".getBytes());
8      delete.addFamily("C1".getBytes());
9      table.delete(delete);
10 }

```

● 删除表

```

1  @Test
2  public void test05() throws IOException {
3      //删除表
4      //判断表是否存在
5      boolean b = admin.tableExists(TableName.valueOf(tableName));
6      if (b) {
7          //判断表是否禁用掉
8          boolean tableEnabled = admin.isTableEnabled(TableName.valueOf(tableName));
9          if (tableEnabled) {
10             //如果没有禁用则先禁用
11             admin.disableTable(TableName.valueOf(tableName));

```

```
12     }
13     //删除表
14     admin.deleteTable(TableName.valueOf(tableName));
15 }
16 }
```

• 导入数据的操作

- 1.把数据从本机上传到虚拟机

```
1 scp part-m-00000_10w root@192.168.88.161:/export/data
```

- 2.从虚拟机上传到hdfs

```
1 hdfs dfs -mkdir -p /water_bill/input
2 hdfs dfs -put /export/data/part-m-00000_10w /water_bill/input
```

- 通过hbase相关命令把数据导入到hbase中
 - 创建一张表

```
1 hbase(main):009:0> create "WATER_BILL", "C1"
```

- 执行导入命令，在终端中执行命令，需要启动yarn

```
1 # hbase org.apache.hadoop.hbase.mapreduce.Import 表名 HDFS数据文件路径
2 # 确保yarn是启动的
3 hbase org.apache.hadoop.hbase.mapreduce.Import WATER_BILL /water_bill/input
```

- 验证数据导入成功

```
1 list
2 验证表是否存在
3
4 hbase shell中执行
5 count "WATER_BILL"
6 得到表所有行数
```

- 写代码进行查询

```
1 ADDRESS LATEST_DATE NAME NUM_CURRENT NUM_PREVIOUS NUM_USAGE PAY_DATE RECORD_DATE SEX
  TOTAL_MONEY
2 rowkey
3
4 select name, num_usage from water_bill where record_date between "2020-06-01" and "2020-
  06-30"
```

基于scan的扫描查询

需求：查询2020年6月所有用户用水量

实现步骤

- 1 1.通过构造scan对象进行全表扫描
 - 2 2.构造过滤器
 - 3 3.通过scan对象进行查询
 - 4 4.把查询结果显示出来
- 前面通过get对象获取的数据是一行数据
现在通过scan对象获取的是多行数据
- 1.值过滤器，针对某个特定列（RECORD_DATE）
SingcolumnValueFilter
 2. $\geq 2020-06-01 < 2020-07-01$
 - 3.BinaryComparator

```
1 @Test
2 public void test06() throws IOException {
3     /**
4      * 1.通过构造scan对象进行全表扫描
5      * 2.构造过滤器
6      * 3.通过scan对象进行查询
7      * 4.把查询结果显示出来
8      */
9     //1.scan对象
10    Scan scan = new Scan();
11    //2.设置过滤器
12    SingleColumnValueFilter startFilter = new SingleColumnValueFilter(
13        "C1".getBytes(), "RECORD_DATE".getBytes(), CompareOperator.GREATER_OR_EQUAL,
14        new BinaryComparator("2020-06-01".getBytes()));
15    SingleColumnValueFilter endFilter = new SingleColumnValueFilter(
16        "C1".getBytes(), "RECORD_DATE".getBytes(), CompareOperator.LESS, new
17        BinaryComparator("2020-07-01".getBytes()));
18    //构造FilterList
19    FilterList filterList = new FilterList();
20    filterList.addFilter(startFilter);
21    filterList.addFilter(endFilter);
```

```

22     scan.setFilter(filterList);
23     //3.进行扫描
24     ResultScanner scanner = table.getScanner(scan);
25     //4.两层for循环
26     for (Result result : scanner) {
27         List<Cell> cells = result.listCells();
28         String rowkey = null;
29         String name = null;
30         String record_date = null;
31         Double num_usage = null;
32         for (Cell cell : cells) {
33             String qualifier = Bytes.toString(CellUtil.cloneQualifier(cell));
34             if ("NAME".equals(qualifier)) {
35                 rowkey = Bytes.toString(CellUtil.cloneRow(cell));
36                 name = Bytes.toString(CellUtil.cloneValue(cell));
37             }
38             if ("RECORD_DATE".equals(qualifier)) {
39                 record_date = Bytes.toString(CellUtil.cloneValue(cell));
40             }
41             if ("NUM_USAGE".equals(qualifier)) {
42                 num_usage = Bytes.toDouble(CellUtil.cloneValue(cell));
43             }
44         }
45         System.out.println("id:" + rowkey + " ,用户名: " + name + " ,日期: " +
46             record_date + " ,用水量: " + num_usage);
47     }
48 }
49
50 }

```

8.HBase的高可用

- hbase高可用就是让hbase主节点有多台，一旦其中主节点挂了，其他备份主节点可以顶上来
- 1.配置

```

1 cd /export/server/hbase-2.1.0/conf
2 vim backup-masters
3 添加以下内容
4 node2

```

5 node3

- 2.把配置文件分发

```
1 scp backup-masters node2:$PWD
2 scp backup-masters node3:$PWD
```

- 重启集群

```
1 stop-hbase.sh 停止集群时出问题，kill命令把进程杀掉
2 start-hbase.sh
```

9.HBase的集群架构

- HMaster主节点作用
 - 1.负责管理从节点
 - 2.负责region分配
 - 3.负责元数据变更处理
- HRegionServer从节点的作用
 - 1.负责管理主节点分配的region
 - 2.负责数据的读写操作
 - 3.负责和主节点保持通信（基于zookeeper）
- 从节点内部结构
 - 1.一个集群可以有多个HRegionServer
 - 2.每个HRegionServer内部有一个HLOG和多个Region组成
 - 3.每个Region内部可以有多个Store模块
 - 4.每个Store模块内部有一个MEMStore和多个StoreFile
 -

- 1 客户端发送写入数据的请求put "day02" , "rk001" , "C1:name" , "zs"
- 2 1.首先连接到zookeeper, 获取hbase:meta表在哪个regionserver
- 3 2.连接对应的regionserver, 获取meta信息, 根据day02表的,
- 4 STARTKEY ENDKEY可以确定要写入的数据在哪个region, 就知道需要写入到哪个regionserver

```
5 3.连接到对象的regionserver，开始进行写入数据操作
6 4.把数据写入到HLOG
7 5.同时把数据写入到memStore，如果有多个列族，则写入多个memStore
8 6.HLOG和MEMStore都写完，客户端认为写入成功
9
10 以上都是客户端流程
11
12 服务端HRegionServer
13
14 7.随着数据越来越多，memStore达到阈值（128M/1小时），触发flush刷新机制，
15 将memStore内容写入到HDFS中（旧版），形成一个storeFile文件
16
17 8.当flush不断进行，HDFS中storeFile（小HFile文件）越来越多，当storeFile文件
18 达到三个及以上，会触发compact合并压缩机制，就会把多个小的HFile文件合并成大的HFile文件
19
20 9.随着HFile越来越大，达到一定阈值时就会水平分割，分成两个新的HFile，对应着两个region，
21 每个region由不同的HRegionServer进行管理（这个分配过程是由HMaster完成）region在分裂过程中不接受读写请求
```

• 11.HBase相关的工作机制

• flush刷新机制（溢写合并机制）

```
1 flush刷新机制的目的：把memStore的数据最终写入到hdfs，形成storefile文件
2 文件阈值：大小阈值128M，时间阈值1小时，满足其中一个就会触发flush刷新机制
3 流程
4 HBase2.0之后flush流程
5 1.关闭当前的memStore空间，接着开启一个信息的memStore空间，接收正常写入
6 2.把关系的memStore放入到一个只读内存队列中，会让这个队列尽可能晚的刷新到磁盘，保证读取效率
7 3.随着队列中的memStore越来越多，当队列达到阈值时，触发flush操作，对队列中的数据进行处理，最后写入到磁盘。形成一个storefile文件。2.0之后才支持该操作
```

• 内存合并操作，在2.0之后支持内存合并操作，默认是不开启，如果要开启需要手动设置

◦ 1.全局设置

```
1 修改hbase-site.xml文件
2 hbase.hregion.compacting.memstore.type
3 none|basic|eager|adaptive
```

• 合并方案

- none：不合并
- basic基础型：合并，不关心是否有重复过期的数据，直接合并，效率高

- eager饥渴型：合并时判断是否有重复过期的数据，清理掉重复过期数据
- adaptive：根据重复过期数据比例进行判断，超过阈值选择eager型否则选择basic
- 2.创建表时指定

```

1 create "test_memory_compaction", {NAME=>"C1", IN_MEMORY_COMPACTION=>"BASIC"}
2
3
4 hbase(main):004:0> create "test_memory_compaction", {NAME=>"C1",
  IN_MEMORY_COMPACTION=>"BASIC"}
5 Created table test_memory_compaction
6 Took 1.6646 seconds
7 => Hbase::Table - test_memory_compaction
8 hbase(main):005:0>

```

storeFile的合并机制

- compact合并压缩机制
- 目的：把多个小的storeFile合并成大的hfile
- 阈值：storeFile达到3个及以上
-
-
- 合并过程中可以进行数据操作
- minor
- 目的：把多个小的storeFile合并成一个较大的storeFile
- 流程：storeFile达到阈值，首先会合并小的，形成一个较大的storeFile
- minor阶段不会对数据进行任何的删除，去重操作，仅仅进行基本的排序，合并工作，整体效率高
-
- major
- 目的：是把上一步较大的storeFile合并成最终的hfile
- 默认情况：达到7天，或者手动执行，触发major操作，会把较大的hfile合并成最终的大Hfile
- 合并过程中重复，过期的数据，都会处理掉，时间长，对HBase产生影响，关闭掉定时触发机制，改成手动执行

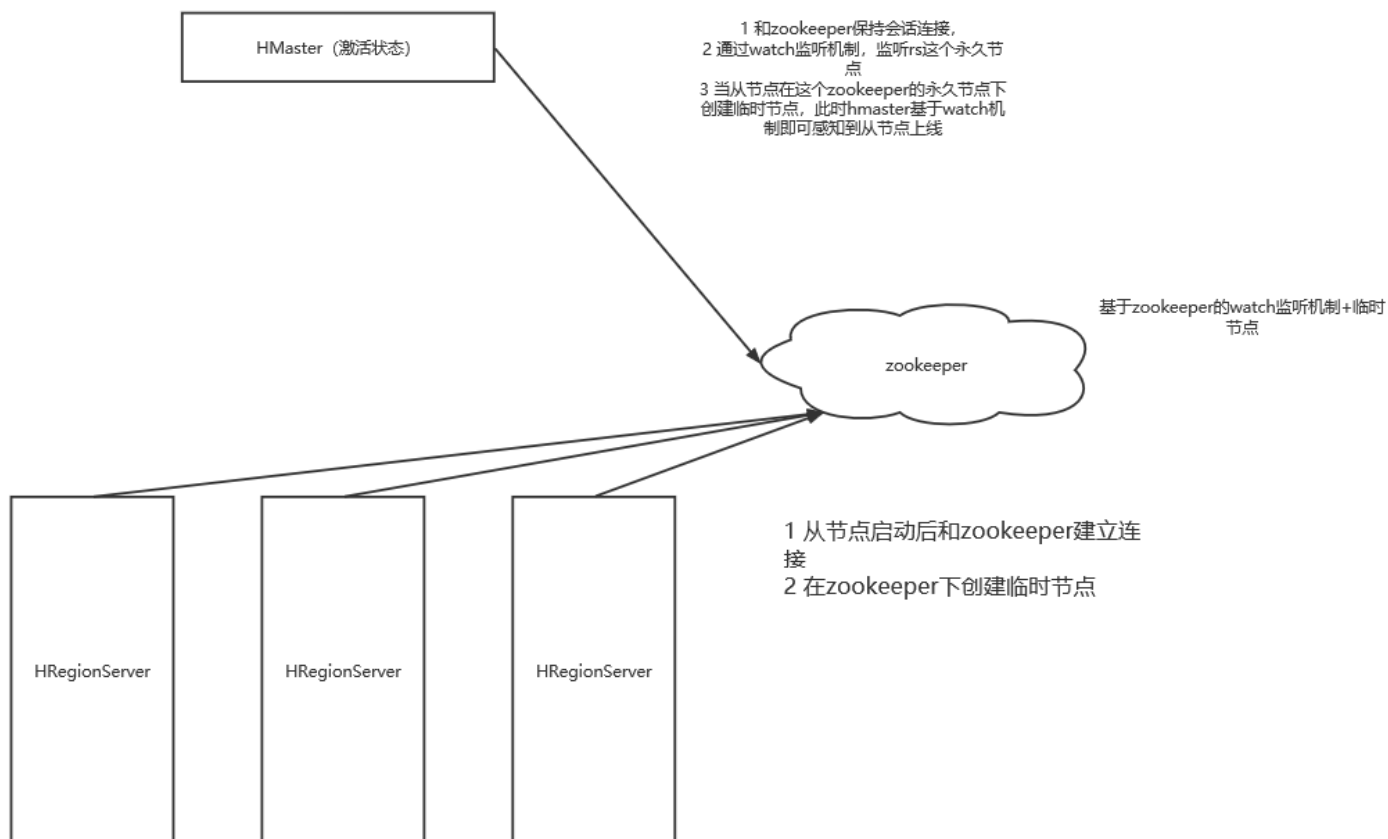
split机制 (region分裂)

- 分裂阈值计算公式： $\min(R^2 * \text{memstore size}, \text{hregion max filesize})$
- R表示的一个表内的region数据
- memstore size=128M
- hregion max filesize 10G

```
5
6 处理值R=1
7 Min (1^2 *128M, 10G)
8 Min(128M, 10G)=128(这种机制是否合理)
9
10 R=2
11 Min (2^2*128, 10G)
12
13 R=9
14 Min(9^2*128, 10G)=10G
15 region/HFile按照10G进行分裂
```

regionServer的上线/下线流程（从节点）

当从节点上线后，主节点马上可以感知到，此时从节点需要把自己管理的region上报给master，master会根据从节点返回的region情况和hbase:meta表查看是否还有未分配的region如果有，则分配，从而实现负载均衡

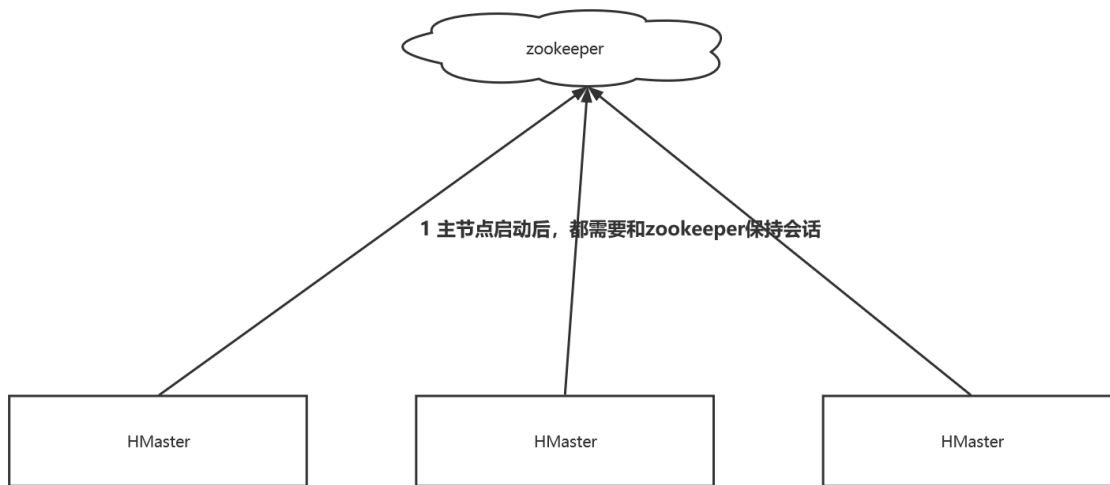


只要从节点下线，则在zookeeper中建立的临时节点就消失
主节点一直在监听rs永久节点，就会发现从节点下线

当从节点下线后，对应的从节点管理的这些region处于无人管理的状态，是未分配状态，此时主节点就需要把这些region重新分配给其他从节点。

如果刚下线的从节点，又上线，此时主节点就会从其他节点中分配一些region给它进行管理，但是不一定是刚从这里分走的

HMaster上线/下线（主节点）



2 各个主节点HMaster都向zookeeper /hbase 创建master的临时节点, 谁先创建成功, 谁就是激活状态的master

3 后来节点只能到backup-masters下创建临时节点, 这些节点就处于备份状态

4 备份状态节点会监听激活状态的节点, 一旦发现master删除, 此时备份状态主节点创建master, 谁先创建成功, 谁是激活状态

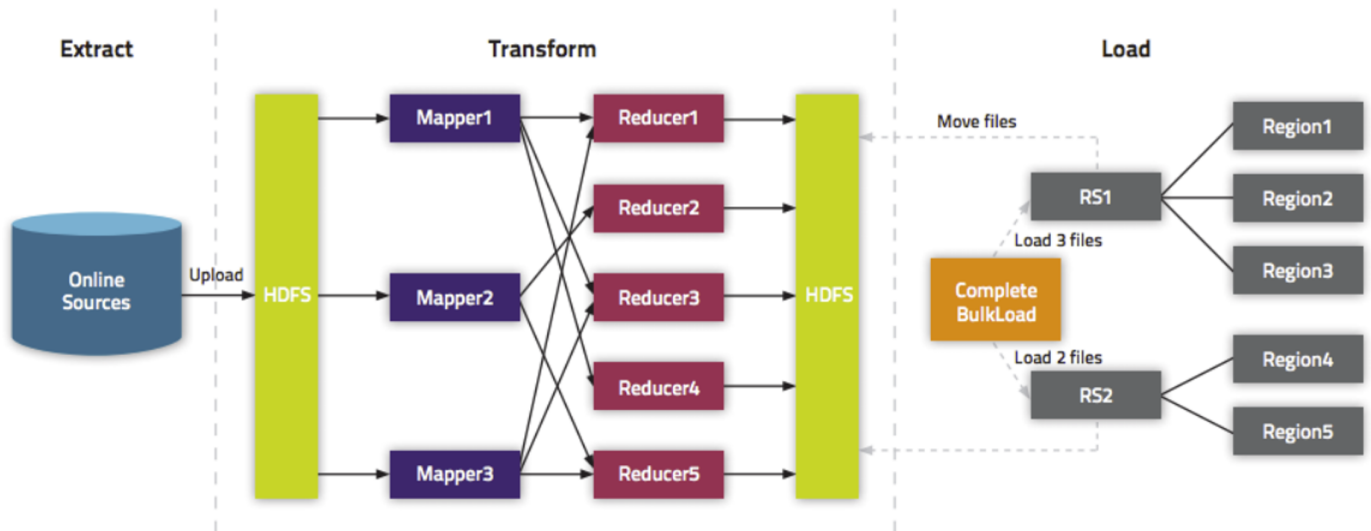
master短暂下线对集群影响, 因为hbase读写操作不经过hmaster, 大多数请求都是读写操作, master下线只会影响元数据的修改, 创建表, 修改表, 删除表

12.Bulk Load 批量加载

- 假如有一批数据, 需要写入到hbase中, 数据量大, 如果采用java api, 流程: 写入到HLOG memStore再从memStore到storeFile, storeFile合并到HFile, HFile有分裂。该过程占用大量资源, 如果有别的请求, 由于写入操作太多, 其他请求就无法执行,
- 解决

1. 把这一批数据直接转成HFile
2. 把HFile导入到hbase, 让hbase直接加载
- 3 跳过流程: 写入HLOG memStore 再从memStore到storeFile, storeFile合并到HFile, HFile又分裂

- 解决的应用场景: 需要一次性写入大量数据



1.1需求说明

- 目前有一份csv文件，里面有大量的转账数据，需要把数据存储到hbase中，原始数据太大，使用bulkload方式进行转换

id	ID
code	流水单号
rec_account	收款账户
rec_bank_name	收款银行
rec_name	收款人姓名
pay_account	付款账户
pay_name	付款人姓名
pay_comments	转账附言
pay_channel	转账渠道
pay_way	转账方式
status	转账状态
timestamp	转账时间
money	转账金额

1.2准备工作

- 需要在hbase中创建一张表

```
1 create "TRANSFER_RECORD", "C1"
```

- 把数据传到hdfs中，需要启动 (hdfs yarn zookeeper hbase)

```
1 [root@node1 data]# hdfs dfs -mkdir -p /hbase/bulkload/input
2 [root@node1 data]# hdfs dfs -put bank_record.csv /hbase/bulkload/input/
```


1.3创建maven工程

- 导入依赖

```
1  <properties>
2      <maven.compiler.source>8</maven.compiler.source>
3      <maven.compiler.target>8</maven.compiler.target>
4  </properties>
5  <repositories>
6      <repository>
7          <id>aliyun</id>
8          <url>http://maven.aliyun.com/nexus/content/groups/public/</url>
9          <releases><enabled>true</enabled></releases>
10         <snapshots><enabled>false</enabled></snapshots>
11     </repository>
12 </repositories>
13
14 <dependencies>
15     <dependency>
16         <groupId>org.apache.hbase</groupId>
17         <artifactId>hbase-client</artifactId>
18         <version>2.1.0</version>
19     </dependency>
20     <dependency>
21         <groupId>commons-io</groupId>
22         <artifactId>commons-io</artifactId>
23         <version>2.6</version>
24     </dependency>
25     <dependency>
26         <groupId>junit</groupId>
27         <artifactId>junit</artifactId>
28         <version>4.12</version>
29     </dependency>
30     <dependency>
31         <groupId>org.testng</groupId>
32         <artifactId>testng</artifactId>
33         <version>6.14.3</version>
34     </dependency>
35     <dependency>
36         <groupId>org.apache.hbase</groupId>
```

```
37         <artifactId>hbase-mapreduce</artifactId>
38         <version>2.1.0</version>
39     </dependency>
40
41     <dependency>
42         <groupId>org.apache.hadoop</groupId>
43         <artifactId>hadoop-mapreduce-client-jobclient</artifactId>
44         <version>2.7.5</version>
45     </dependency>
46
47     <dependency>
48         <groupId>org.apache.hadoop</groupId>
49         <artifactId>hadoop-common</artifactId>
50         <version>2.7.4</version>
51     </dependency>
52
53     <dependency>
54         <groupId>org.apache.hadoop</groupId>
55         <artifactId>hadoop-mapreduce-client-core</artifactId>
56         <version>2.7.4</version>
57     </dependency>
58     <dependency>
59         <groupId>org.apache.hadoop</groupId>
60         <artifactId>hadoop-auth</artifactId>
61         <version>2.7.4</version>
62     </dependency>
63
64     <dependency>
65         <groupId>org.apache.hadoop</groupId>
66         <artifactId>hadoop-hdfs</artifactId>
67         <version>2.7.4</version>
68     </dependency>
69 </dependencies>
70
71 <build>
72     <plugins>
73         <plugin>
74             <groupId>org.apache.maven.plugins</groupId>
75             <artifactId>maven-compiler-plugin</artifactId>
76             <version>3.1</version>
```

```

77         <configuration>
78             <target>1.8</target>
79             <source>1.8</source>
80         </configuration>
81     </plugin>
82 </plugins>
83 </build>

```

1.4csv文件转成HFile文件

- 编写mapper代码

```

1  package sz.base.habse;
2
3  import org.apache.hadoop.hbase.client.Put;
4  import org.apache.hadoop.hbase.io.ImmutableBytesWritable;
5  import org.apache.hadoop.io.LongWritable;
6  import org.apache.hadoop.io.Text;
7  import org.apache.hadoop.mapreduce.Mapper;
8
9  import java.io.IOException;
10
11 public class mapper extends Mapper<LongWritable, Text, ImmutableBytesWritable, Put> {
12     //ImmutableBytesWritable（接口）是一个数据类型一般作为RowKey的类型
13     private ImmutableBytesWritable k2 = new ImmutableBytesWritable();
14
15     @Override
16     protected void map(LongWritable key, Text value, Context context) throws
17     IOException, InterruptedException {
18         //1.获取一行数据
19         String line = value.toString();
20         //2.对数据进行分割,进行判断如果不为空和null则为true
21         if (line != null && !"".equals(line)) {
22             //对每行数据进行切割，切割符号为：，
23             String[] fields = line.split(",");
24             //获取第0个元素，用作rowkey
25             byte[] rowkey = fields[0].getBytes();
26             //转换为ImmutableBytesWritable类型
27             k2.set(rowkey);
28             //3.构造put对象

```

```

28         //rowkey是一个行健
29         Put v2 = new Put(rowkey);
30         //添加数据
31         v2.addColumn("C1".getBytes(), "code".getBytes(), fields[1].getBytes());
32         v2.addColumn("C1".getBytes(), "rec_account".getBytes(),
33         fields[2].getBytes());
34         v2.addColumn("C1".getBytes(), "rec_bank_name".getBytes(),
35         fields[3].getBytes());
36         v2.addColumn("C1".getBytes(), "rec_name".getBytes(), fields[4].getBytes());
37         v2.addColumn("C1".getBytes(), "pay_account".getBytes(),
38         fields[5].getBytes());
39         v2.addColumn("C1".getBytes(), "pay_name".getBytes(), fields[6].getBytes());
40         v2.addColumn("C1".getBytes(), "pay_comments".getBytes(),
41         fields[7].getBytes());
42         v2.addColumn("C1".getBytes(), "pay_channel".getBytes(),
43         fields[8].getBytes());
44         v2.addColumn("C1".getBytes(), "pay_way".getBytes(), fields[9].getBytes());
45         v2.addColumn("C1".getBytes(), "status".getBytes(), fields[10].getBytes());
46         v2.addColumn("C1".getBytes(), "timestamp".getBytes(),
47         fields[11].getBytes());
48         v2.addColumn("C1".getBytes(), "money".getBytes(), fields[12].getBytes());
49         //4.数据写出去
50         context.write(k2, v2);
51     }
52 }
53 }
54 }

```

• 编写driver代码

```

1  package sz.base.java;
2
3  import org.apache.hadoop.conf.Configuration;
4  import org.apache.hadoop.conf.Configured;
5  import org.apache.hadoop.fs.Path;
6  import org.apache.hadoop.hbase.HBaseConfiguration;
7  import org.apache.hadoop.hbase.TableName;
8  import org.apache.hadoop.hbase.client.Connection;
9  import org.apache.hadoop.hbase.client.ConnectionFactory;
10 import org.apache.hadoop.hbase.client.Put;
11 import org.apache.hadoop.hbase.client.Table;
12 import org.apache.hadoop.hbase.io.ImmutableBytesWritable;

```

```
13 import org.apache.hadoop.hbase.mapreduce.HFileOutputFormat2;
14 import org.apache.hadoop.mapreduce.Job;
15 import org.apache.hadoop.mapreduce.lib.input.TextInputFormat;
16 import org.apache.hadoop.util.Tool;
17 import org.apache.hadoop.util.ToolRunner;
18 import org.apache.zookeeper.ZooKeeper;
19
20 public class BulkLoadDriver extends Configured implements Tool {
21     @Override
22     public int run(String[] strings) throws Exception {
23         //1.创建job对象
24         Job job = Job.getInstance(super.getConf(), "BulkLoadDriver");
25         //2.设置yarn参数
26         job.setJarByClass(BulkLoadDriver.class);
27         //3.设置八步
28         //3.1设置输入类，输入路径
29         job.setInputFormatClass(TextInputFormat.class);
30         TextInputFormat.addInputPath(job, new
Path("hdfs://node1:8020/hbase/bulkload/input/"));
31         //3.2设置mapper，输出k2，v2
32         job.setMapperClass(BulkLoadMapper.class);
33         job.setMapOutputKeyClass(ImmutableBytesWritable.class);
34         job.setMapOutputValueClass(Put.class);
35         //3.3设置shuffle分区 排序 规约 分组
36         //3.7设置reduce reduce输出 k3 , v3
37         job.setNumReduceTasks(0);
38         job.setOutputKeyClass(ImmutableBytesWritable.class);
39         job.setOutputValueClass(Put.class);
40         //3.8设置输出类 输出路径
41         job.setOutputFormatClass(HFileOutputFormat2.class);
42         //4.获取hbase连接对象
43         Connection hbconn = ConnectionFactory.createConnection(super.getConf());
44         System.out.println(hbconn);
45         Table table = hbconn.getTable(TableName.valueOf("TRANSFER_RECORD"));
46         //设置输出路径
47         HFileOutputFormat2.configureIncrementalLoad(job, table,
hbconn.getRegionLocator(TableName.valueOf("TRANSFER_RECORD")));
48         HFileOutputFormat2.setOutputPath(job, new
Path("hdfs://node1:8020/hbase/bulkload/output/"));
49         //提交任务
50         boolean b = job.waitForCompletion(true);
```

```

51
52     return b ? 0 : 1;
53 }
54
55 public static void main(String[] args) throws Exception {
56     System.setProperty("HADOOP_USER_NAME", "root");
57     Configuration conf = HBaseConfiguration.create();
58     conf.set("hbase.zookeeper.quorum", "node1");
59     int run = ToolRunner.run(conf, new BulkLoadDriver(), args);
60     System.out.println(run);
61 }
62
63 }
64

```

• 可能出现的问题

```
1 Mkdirs failed to create xxx/hbase-staging
```

- 在main函数中添加

```

1 System.setProperty("HADOOP_USER_NAME", "root");
2 conf.set("fs.defaultFS", "hdfs://node1:8020");

```

- 修改配置文件
- /export/server/hadoop/etc/hadoop/core-site.xml

```

1 <property>
2     <name>fs.defaultFS</name>
3     <value>hdfs://node1.itcast.cn:8020</value>
4 </property>

```

1.5验证代码执行结果

```

1 [root@node1 hadoop]# hdfs dfs -ls /hbase/bulkload/output
2 Found 2 items
3 drwxr-xr-x   - root supergroup          0 2022-03-10 10:44 /hbase/bulkload/output/C1
4 -rw-r--r--   3 root supergroup          0 2022-03-10 10:45
   /hbase/bulkload/output/_SUCCESS
5
6 可以看到_SUCCESS表示执行成功

```

Browse Directory

/hbase/bulkload/output

Go!

Show

25

entries

Search:

<input type="checkbox"/>	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
<input type="checkbox"/>	drwxr-xr-x	root	supergroup	0 B	Mar 10 10:44	0	0 B	C1	
<input type="checkbox"/>	-rw-r--r--	root	supergroup	0 B	Mar 10 10:45	3	128 MB	_SUCCESS	

Showing 1 to 2 of 2 entries

Previous

1

Next

1.6把HFile格式文件加载到hbase中

- 命令是在终端中运行，liunx中

```
1 格式：hbase org.apache.hadoop.hbase.tool.LoadIncrementalHFiles 代码产生的数据路径 Hbase表名
2 hbase org.apache.hadoop.hbase.tool.LoadIncrementalHFiles
  hdfs://node1:8020/hbase/bulkload/output/ TRANSFER_RECORD
```

- 验证数据

```
1 在hbase shell中统计表的行数
2 count "TRANSFER_RECORD"
3 和原始的csv文件数量一致
```

- 执行完导入命令后，通过Java代码生成的数据就被删除了。数据已经导入到hbase表

Browse Directory

/hbase/bulkload/output/C1

Go!

Show

25

entries

Search:

<input type="checkbox"/>	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
No data available in table									

Showing 0 to 0 of 0 entries

Previous

Next

13.HBase和Hive的集成操作

- 1.hbase hive对比
 - hive是一个数仓工具，基于hadoop数据存在datanade上，执行翻译把sql翻译成mr，主要离线分析中使用，延迟较高
 - hbase数据存储容器，NoSQL数据库，基于hdfs，数据以HFile格式存在，不支持sql，延迟较低，有很高的随机读写能力
 - hive hbase都是基于hadoop的不同的工具，可以同时使用，可以集成在一起使用
 - 把hive hbase集成在一起，通过hive进行离线分析，通过hbase执行高效读写操作
- 2.hive和hbase集成操作

- 拷贝hive和hbase进行通信的包到hbase的lib目录

```
1 [root@node1 ~]# cd /export/server/hive/lib/
2 [root@node1 lib]# ll hive-hbase-handler-3.1.2.jar
3 -rw-r--r-- 1 root root 118060 Aug 23 2019 hive-hbase-handler-3.1.2.jar
4 [root@node1 lib]# cp hive-hbase-handler-3.1.2.jar /export/server/hbase-2.1.0/lib/
```

- 修改hive的配置文件

```
1 [root@node1 conf]# cd /export/server/hive/conf
2 [root@node1 conf]# vim hive-site.xml
3
4 添加以下内容
5
6 <property>
7     <name>hive.zookeeper.quorum</name>
8     <value>node1,node2,node3</value>
9 </property>
10 <property>
11     <name>hbase.zookeeper.quorum</name>
12     <value>node1,node2,node3</value>
13 </property>
14 <property>
15     <name>hive.server2.enable.doAs</name>
16     <value>false</value>
17 </property>
18
```

```
1 [root@node1 conf]# cd /export/server/hive/conf
2 [root@node1 conf]# vim hive-env.sh
3
4 添加以下内容
5
6 export HADOOP_HOME=/export/server/hadoop-3.3.0
7 export HIVE_CONF_DIR=/export/server/hive-3.1.2/conf
8 export HBASE_HOME=/export/server/hbase-2.1.0
9
```

• 3.分发jar包

```
1 [root@node1 conf]# cd /export/server/hbase-2.1.0/lib/
```

```
2 [root@node1 lib]# scp hive-hbase-handler-3.1.2.jar node2:$PWD
3 hive-hbase-handler-3.1.2.jar
   100% 115KB 37.1MB/s 00:00
4 [root@node1 lib]# scp hive-hbase-handler-3.1.2.jar node3:$PWD
5 hive-hbase-handler-3.1.2.jar
   100% 115KB 20.8MB/s 00:00
```

4.启动集群

```
1 1 启动hadoop集群
2 start-all.sh
3 或者
4 start-dfs.sh
5 start-yarn.sh
6
7 2 启动zookeeper，确保三台节点都启动
8 三台节点都要执行
9 zkServer.sh start
10
11 3 启动hbase集群，在node1上启动
12 start-hbase.sh
13
14 4 启动hive，需要把hive添加到环境变量中，修改/etc/profile文件，source /etc/profile
15 nohup hive --service metastore 2>&1 &
16 nohup hive --service hiveserver2 2>&1 &
```

• 5.创建hbase表（测试）

```
1 hbase(main):017:0> create "hbase_hive_score", "cf"
2 Created table hbase_hive_score
3 Took 0.7717 seconds

4 => Hbase::Table - hbase_hive_score
5 hbase(main):018:0> put "hbase_hive_score", "1", "cf:name", "zhangsan"
6 Took 0.1243 seconds

7 hbase(main):019:0> put "hbase_hive_score", "1", "cf:score", "95"
8 Took 0.0068 seconds

9 hbase(main):020:0> put "hbase_hive_score", "2", "cf:name", "lisi"
```

```
10 Took 0.0070 seconds

11 hbase(main):021:0> put "hbase_hive_score", "2", "cf:score", "96"

12 Took 0.0053 seconds

13 hbase(main):022:0> put "hbase_hive_score", "3", "cf:name", "wangwu"

14 Took 0.0064 seconds

15 hbase(main):023:0> put "hbase_hive_score", "3", "cf:score", "97"

16 Took 0.0069 seconds

17 hbase(main):024:0>
```

6.创建hive表

```
1  创建hive关联到hbase，这个hive表是一个外部表，
2
3  格式
4
5  create external table 数据库名.表名 (
6  字段1 类型,
7  字段2 类型,
8  字段3 类型,
9  ....
10 ) stored by "org.apache.hadoop.hive.hbase.HBaseStorageHandler" WITH SERDEPROPERTIES
    ("hbase.columns.mapping"=":key,列族1:列名1,列族2:列名2,...")
    TBLPROPERTIES("hbase.table.name"="hbase表名");
11
12
13 例子
14
15 create external table hbase_hive_score (
16 id int,
17 name string,
18 score int
19 ) stored by "org.apache.hadoop.hive.hbase.HBaseStorageHandler" WITH SERDEPROPERTIES
    ("hbase.columns.mapping"=":key,cf:name,cf:score")
    TBLPROPERTIES("hbase.table.name"="hbase_hive_score");
20
21
22 查询
23 select * from hbase_hive_score;
```

	id	name	score
1	1	zhangsan	97
2	2	lisi	90
3	3	wangwu	98

14.HBase表结构设计

• 1.hbase名称空间/命名空间

- 问题：MySQL hive中为什么创建数据库
 - 便于管理和维护
 - 业务划分更加明确
 - 进行权限管理
- 在hbase中，名称空间/命名空间也有同样作用
- hbase中namespace作用就是类似于MySQL hive 中数据库的作用，只不过在hbase中叫做namespace
- hbase有两个默认的名称空间 defalut和hbase

Browse Directory

Go!

Show 25 entries

Search:

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
drwxr-xr-x	root	supergroup	0 B	Mar 10 11:08	0	0 B	TRANSFER_RECORD
drwxr-xr-x	root	supergroup	0 B	Mar 08 10:09	0	0 B	WATER_BILL
drwxr-xr-x	root	supergroup	0 B	Mar 07 14:40	0	0 B	day01
drwxr-xr-x	root	supergroup	0 B	Mar 10 14:28	0	0 B	hbase_hive_score
drwxr-xr-x	root	supergroup	0 B	Mar 08 16:38	0	0 B	test_memory_compaction

Showing 1 to 5 of 5 entries

Previous 1 Next

Browse Directory

Go!

Show 25 entries

Search:

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
drwxr-xr-x	root	supergroup	0 B	Mar 07 10:52	0	0 B	meta
drwxr-xr-x	root	supergroup	0 B	Mar 07 10:52	0	0 B	namespace

Showing 1 to 2 of 2 entries

Previous 1 Next

- default名称空间：默认名称空间，创建表时如果没有指定名称空间，则都是在default下创建
 - hive有一个default数据库
- hbase名称空间：专门防止hbase内部管理表的，一般不会操作，有hbase自己维护
 - meta表，就是hbase元数据表
 - 极端情况，比如系统出问题，某些表无法删除，可以操作hbase：meta表

• 2.名称空间命令

```
1 1 创建名称空间
2 create_namespace "名称空间"
3 create_namespace "day03_space"
4
5 2 查看名称空间
6 list_namespace
7
8 3 查看名称空间信息
9 describe_namespace "名称空间"
10 describe_namespace "day03_space"
11
12 4 在某个名称空间中创建表
13 create "名称空间:表名", "列族"...
14 创建表时指定名称空间，后续所有操作都需要带名称空间，否则hbase会到default中找这个表
15
16 5 删除名称空间
17 drop_namespace "名称空间"
18 必须确保这个名称空间没有表
```

● 3.hbase表列族设计

- 原则：建表时，如果能用一个列族解决的，坚决只用一个，能少则少
- 原因：创建表时列族过多，region就会有多个store模块，每个store模块又由memStore和storeFile构成，导致读写数据时需要跨多个内存和文件，增大io操作，效率就降低，列族过多会导致region刷新触发compact压缩
- 什么场景使用多个列族
 - 假设有一张表，字段比较多，有些字段常用，可把性质相同的列放在一个列族中。如果把所有的数据都放在一个列族，在执行扫描操作时会把所有数据都取出来，降低效率
 - 假设一张表，字段比较多，对接同的业务，不同业务创建不同列族，各个业务之间读取各自的数据，互不影响
 - 2-5列族

4.hbase压缩方案

压缩算法	压缩后占比	压缩	解压缩
GZIP	13.4%	21 MB/s	118 MB/s
LZO	20.5%	135 MB/s	410 MB/s
Zippy/Snappy	22.2%	172 MB/s	409 MB/s

- 生产中如何选择

```
1 1 要压缩，如果数据频繁读写，可以选择snappy算法
2 2 要压缩，如果数据需要大量写入，但是读取很少时，采用gzip压缩算法
```

- 默认情况，创建表时不压缩

```
hbase(main):040:0> describe "WATER_BILL"
Table WATER_BILL is ENABLED
WATER_BILL
COLUMN FAMILIES DESCRIPTION
{NAME => 'C1', VERSIONS => '1', EVICT_BLOCKS_ON_CLOSE => 'false', NEW_VERSION_BEHAVIOR => 'false', KEEP_DELETED_CELLS => 'FALSE',
  CACHE_DATA_ON_WRITE => 'false', DATA_BLOCK_ENCODING => 'NONE', TTL => 'FOREVER', MIN_VERSIONS => '0', REPLICATION_SCOPE => '0',
  BLOOMFILTER => 'ROW', CACHE_INDEX_ON_WRITE => 'false', IN_MEMORY => 'false', CACHE_BLOOMS_ON_WRITE => 'false', PREFETCH_BLOCKS_ON
  _OPEN => 'false', COMPRESSION => 'NONE', BLOCKCACHE => 'true', BLOCKSIZE => '65536'}
1 row(s)
Took 0.0722 seconds
hbase(main):041:0>
```

- 指定压缩方案

- 格式
- 创建表时
- create "表名", {NAME=>"列族", COMPRESSION=>"GZ|SNAPPY|LZO"}
-
- create "day03", {NAME=>"C1", COMPRESSION=>"GZ"} # 压缩方案是针对列族
-
- 对于已经存在的表，需要修改压缩方案，使用alter命令
- alter "表名", {NAME=>"列族", COMPRESSION=>"GZ|SNAPPY|LZO"}
-
- 如果使用snappy压缩，需要重新编译hbase，让hbase支持snappy压缩
- 使用lzo压缩，需要把lzo的jar放在指定环境中
-

default	TRANSFER_RECORD	1	0	0	0	0	'TRANSFER_RECORD', (NAME => 'C1')
default	WATER_BILL	1	0	0	0	0	'WATER_BILL', (NAME => 'C1')
default	day01	1	0	0	0	0	'day01', (NAME => 'f1'), (NAME => 'f2')
default	day03	1	0	0	0	0	'day03', (NAME => 'C1', COMPRESSION => 'GZ')
default	hbase_hive_score	1	0	0	0	0	'hbase_hive_score', (NAME => 'cf')
default	test_memory_compaction	1	0	0	0	0	'test_memory_compaction', (NAME => 'C1', METADATA => {'IN_MEMORY_COMPACTION' => 'BASIC'})

5.hbase表的预分区

- 默认情况，hbase一个表只有一个region，而一个region只能由一个regionserver进行管理
- 如果一开始来了大量读写操作，这个regionserver可能会宕机，因为这个regionserver管理所有的读写情况
- 如果解决

- 如果创建表时，一次性构建多个region，多个region、均匀分布在regionserver上，此时来了大量的读写请求，这些请求就可以分发达到不同regionserver，就解决了这个问题

一条数据，rowkey10
问这个数据落在哪个region?
region3

1 15 2 200 1314按照字典序排序
1 1314 15 2 200

HBase表					
rowkey	C1(列族)		C2(列族)		
	name	age	address	sex	
rowkey01	张三	20	上海	男	
rowkey02	李四	21	北京	女	
rowkey03	王五	19	广州	男	
rowkey04	赵六	18	深圳	女	
rowkey05	钱七	25	武汉	男	
rowkey06	孙八	27	杭州	女	

新添加的数据放在哪个region
有几种方式
1 根据rowkey进行hash计算，对hash值进行取模运算，根据得到的余数放到对应的region
2 轮着来，第一个数据放在第一个region，以此类推
3 指定region

hbase中选择哪个方案
以上方案hbase都不采用
hbase采用Start KeyEnd Key
传入一条数据，根据数据rowkey的字典序进行判断，判断落在哪个region对应的范围内，就把数据放在哪个region

- 如何实现预分区
 - 手动设定分区边界

- 1 格式
- 2 create "表名", "列族", SPLITS=>[分区边界值]
- 3
- 4 create "test3", "C1", SPLITS=>['10', '20', '30', '40']
- 5 这里是四个边界值，得到五个分区
- 6 左闭右开['10', '20') '10' rowkey落在这个分区，'20'这个rowkey落在下一个分区
- 7
- 8 '200' rowkey落在哪个分区？落在第2个分区

Table Regions

Sort As RegionName Ascending ShowDetailName&Start/End Key Reorder

Name(5)	Region Server	ReadRequests (0)	WriteRequests (0)	StorefileSize (0 B)	Num.Storefiles (0)	MemSize (0 B)	Locality	Start Key	End Key
test3,,1646901103780.afa2495fec31fd5fdefe71cca2e63e76.	node3:16030	0	0	0 B	0	0 B	0.0	10	
test3,10,1646901103780.c926ae12092b33e274b9ac982659e820.	node2:16030	0	0	0 B	0	0 B	0.0	10	20
test3,20,1646901103780.5c9a864b9cc5b2c7efaff1ebab4472a8.	node3:16030	0	0	0 B	0	0 B	0.0	20	30
test3,30,1646901103780.675797d56d07dca9cf4727605f435a32.	node2:16030	0	0	0 B	0	0 B	0.0	30	40
test3,40,1646901103780.88c1d12287d2d24aea9bf6bec1a13d6f.	node2:16030	0	0	0 B	0	0 B	0.0	40	

- hash分区方案

- 1 格式
- 2 create "表名", "列族", {NUMREGIONS=>N, SPLITALGO=>"HexStringSplit"}
- 3 通过HexStringSplit算法确定分区边界
- 4
- 5 create "test04", "C1", {NUMREGIONS=>16, SPLITALGO=>"HexStringSplit"}

Table Regions

Sort As RegionName Ascending ☐ ShowDetailName&Start/End Key ☒ Reorder

Name(16)	Region Server	ReadRequests (0)	WriteRequests (0)	StorefileSize (0 B)	Num.Storefiles (0)	MemSize (0 B)	Locality	Start Key	End Key
test04,,1646901575103.0eb469aef8a4393d984bfd60719b26b.	node2:16030	0	0	0 B	0	0 B	0.0		10000000
test04,10000000,1646901575103.ba8683913a5328d228eab690deb75218.	node2:16030	0	0	0 B	0	0 B	0.0	10000000	20000000
test04,20000000,1646901575103.491d7cdbd165676742bde321ff204d38.	node3:16030	0	0	0 B	0	0 B	0.0	20000000	30000000
test04,30000000,1646901575103.7b3c941770ba2f5b1e7af01db47cfe08.	node2:16030	0	0	0 B	0	0 B	0.0	30000000	40000000
test04,40000000,1646901575103.fc66890d5977864fe9ea3891a84ba8ae.	node3:16030	0	0	0 B	0	0 B	0.0	40000000	50000000
test04,50000000,1646901575103.3b314e131ebf39ed3318aaf49496eae2.	node2:16030	0	0	0 B	0	0 B	0.0	50000000	60000000
test04,60000000,1646901575103.e1eb3403d0ecf4869aee7eef29b9c74.	node3:16030	0	0	0 B	0	0 B	0.0	60000000	70000000
test04,70000000,1646901575103.c2bc94851367b0d4a64b3057f13c996c.	node3:16030	0	0	0 B	0	0 B	0.0	70000000	80000000
test04,80000000,1646901575103.5f83ef97c6802b7abb87b48ed33ac2c5.	node2:16030	0	0	0 B	0	0 B	0.0	80000000	90000000
test04,90000000,1646901575103.1dd765d253fa7884231c24694b026108.	node2:16030	0	0	0 B	0	0 B	0.0	90000000	a0000000
test04,a0000000,1646901575103.f2d3f1eeeb8a40432581bcd8ad5a37900.	node2:16030	0	0	0 B	0	0 B	0.0	a0000000	b0000000
test04,b0000000,1646901575103.9149ecc82908e171d12a89313ef565f0.	node3:16030	0	0	0 B	0	0 B	0.0	b0000000	c0000000
test04,c0000000,1646901575103.662e10bab4c02f6e2db6d1c940f21bba.	node3:16030	0	0	0 B	0	0 B	0.0	c0000000	d0000000
test04,d0000000,1646901575103.cc3ee34671f4b8a399eefc6f7c9ec6f4.	node3:16030	0	0	0 B	0	0 B	0.0	d0000000	e0000000
test04,e0000000.1646901575103.65aff9ec73b32346da91c426f3f650862.	node2:16030	0	0	0 B	0	0 B	0.0	e0000000	f0000000

6.hbase中rowkey设计原则

- 问题：前面的预分区方案，有没有问题？

1 前面进行预分区目的？期望保证负载均衡，但是完全依靠预分区可能没办法解决负载不均衡问题。如果rowkey没有设计好，会出现所有的数据落在一个region中

- 解决方案：在预分区的基础上，设计好rowkey保证数据均匀分布在不同region上，如果rowkey设计不好，会导致数据不均衡
- 设置rowkey原则

- 1 1 避免使用递增的行键/时序数据
- 2 0 1 2 3 4 ...
- 3 ~ 10000
- 4 10000 ~ 20000
- 5
- 6 时间戳，最前面那一位需要很久才会变化，导致数据集中在前面的分区中
- 7 2 避免使用rowkey和列名过长
- 8 因为列名和rowkey和数据一起存在hfile中，如果太长，相应数据就存不了太多，导致提前flush操作
- 9
- 10 rowkey 支持64k byte
- 11 一般建议100个字节，大部分在10-20个字节
- 12
- 13 3 使用long型比string更节省空间
- 14 100
- 15
- 16 "100" 占 3字节
- 17 100 占 一个字节= 8 bit 无符号 0-255 ， 1个字节就可以存
- 18


```
19
20 4 保证rowkey唯一性
21 如果不唯一，也不会报错，只会把原来数据覆盖掉
22
23
```

- 如果避免出现热点数据
 - 热点是指大量的客户端直接访问集群的一个或者几个节点（读写），大量访问量可能会使得某个服务器节点超负荷，导致整个regionserver性能下降，其他的region也会受影响
 - 反转操作
 - 反转策略可以使rowkey随机分布，但是牺牲了rowkey的有序性
 - 比如手机号码，12345678，翻转：87654321
 - 缺点：利于get操作，但不利于scan操作，因为数据在原rowkey上的自然顺序已经被打乱
 - 加盐策略
 - 在rowkey钱加上随机字符串或者随机数
 - 随机数能保障数据在所有region件的负载均衡
 - 如果采用上面两种策略，对于相关性很强的数据，就会被打散到不同的region
 - 比如：2022031001-2022031999 2022032001-2022032999
 - 哈希策略
 - 内容相同的部分进行hash运算，得到的结果一致的，再把这个hash和其他部分进行拼接
 - 这样可以得到分布均匀并且相关性强的数据分在一起

15.hbase版本确界

- 版本确界，在hbase中历史数据的版本，定义数据的历史版本保留多少个
- 下界：MIN_VERSIONS，hbase中单元格(cell)至少要保留几个版本，即时数据已经过期，默认值0（禁用），和TTL相结合，即只有一个值写入cell
- 上界：VERSIONS，hbase中单元格最多保留几个版本，如果版本比设置的VERSIONS大，最早进入系统的数据就会被覆盖，默认值是1（基于时间戳）

1.TTL

- Time to live，数据存活时间，hbase中可以针对数据设置过期时间，时间过期后，hbase会自动清除数据
- 代码实现

```
1 package sz.base.java.hbase.version_ttl;
2
3 import org.apache.hadoop.conf.Configuration;
4 import org.apache.hadoop.hbase.Cell;
5 import org.apache.hadoop.hbase.CellUtil;
```

```
6 import org.apache.hadoop.hbase.HBaseConfiguration;
7 import org.apache.hadoop.hbase.TableName;
8 import org.apache.hadoop.hbase.client.*;
9 import org.apache.hadoop.hbase.util.Bytes;
10
11 import java.io.IOException;
12
13 public class HBaseVersionTTLTest {
14     //1.创建一个hbase表, 设置上界和下界 ttl
15     //2.添加数据, 进行修改操作, 让数据达到设置的上界
16     //3.查询数据, 观察现象
17     public static void main(String[] args) throws IOException {
18         //1.获取hbase链接对象
19         Configuration conf = HBaseConfiguration.create();
20         conf.set("hbase.zookeeper.quorum", "node1");
21         Connection hbcon = ConnectionFactory.createConnection(conf);
22         Admin admin = hbcon.getAdmin();
23         boolean flag = admin.tableExists(TableName.valueOf("day03"));
24         if (!flag) {
25             //如果执行代码到这里, 表示不存在 把c1转换成byte
26             //3.1创建列族相关的构造器, 设置列族名
27             ColumnFamilyDescriptorBuilder columnFamilyDescriptorBuilder =
28             ColumnFamilyDescriptorBuilder.newBuilder("C1".getBytes());
29             columnFamilyDescriptorBuilder.setMinVersions(3);//设置下界
30             columnFamilyDescriptorBuilder.setMaxVersions(5);//设置上界
31             //下界30秒, 过期数据会被清理, 下界设置了3个, 则会保留最新3条数据
32             columnFamilyDescriptorBuilder.setTimeToLive(30);//TTL 30秒
33             ColumnFamilyDescriptor build1 = columnFamilyDescriptorBuilder.build();
34             //3.2创建表相关的构造器, 设置表名和列族名
35             TableDescriptorBuilder mater_bill =
36             TableDescriptorBuilder.newBuilder(TableName.valueOf("day03"));
37             //设置列族名
38             mater_bill.setColumnFamily(build1);
39             //3.3创建构造器和表构造器关联, 确定列族和表名
40             TableDescriptor build = mater_bill.build();
41             //3.4创建表
42             admin.createTable(build);
43         }
44         Table table = hbcon.getTable(TableName.valueOf("day03"));
45         //添加数据, 上界为5添加6条
```

```

44 //      for (int i = 0; i <= 6; i++) {
45 //          Put put = new Put("rk001".getBytes());
46 //          String name = "zhangsan" + i;
47 //          System.out.println(name);
48 //          put.addColumn("C1".getBytes(), "NAME".getBytes(), name.getBytes());
49 //          table.put(put);
50 //      }
51 //查询 数据
52 Get get = new Get("rk001".getBytes());
53 get.readAllVersions();//执行这个函数才能把所有符合规则的版本都获取到
54 Result result = table.get(get);
55
56 //打印结果
57 Cell[] cells = result.rawCells();
58 for (Cell cell : cells) {
59     System.out.println(Bytes.toString(CellUtil.cloneValue(cell)));
60 }
61 }
62 }


```

16.HBase的协处理器

1.协处理器的基本介绍

- observer协处理器

observer会监听某些事件，一旦这个事件要发生或者发生完成，observer会执行提前定义好的行为



- endpoint

- 1 协处理器是可以看做定义了一个方法，把这个方法放置再regionserver上运行，各个regionserver运行后把结果返回给客户端
- 2 聚合操作 `max sum count`

2.如何设置协处理器

- 1.静态的全局设置

- 在hbase-site.xml文件中进行设置，全局有效，设置后对每个hbase表都会有协处理器

```
1 <property>
2     <name>hbase.coprocessor.user.region.classes</name>
3     <value>org.apache.hadoop.hbase.coprocessor.AggregateImplementation</value>
4 </property>
```

- 2.动态设置，只针对某个表有效

- 禁用表
- 添加协处理器

```
1 hbase> alter 'mytable', METHOD => 'table_att','coprocessor' =>
  '|org.apache.Hadoop.hbase.coprocessor.AggregateImplementation|'
```

- 启用表

- 3.如何卸载协处理器

- 禁用表
- 删除协处理器

```
1 alter 'test' , METHOD => 'table_att_unset',NAME=> 'coprocessor$1'
```

- 启用表

- 17.HBase调优